

MVP — Engenharia de Dados

Evidências de Execução e Resultados

Pipeline de análise do desempenho musical no Spotify

Documento complementar ao notebook final e ao README do repositório. As imagens foram selecionadas dos screenshots produzidos durante a execução do MVP e recortadas para preservar apenas a evidência relevante.

1. Fonte, proveniência e licença




Figura 1 — Fonte e licença dos dados

Dataset Most Streamed Spotify Songs 2023 no Kaggle, com a licença identificada como “Other (specified in description)”.




Figura 2 — Documentação da fonte, proveniência e linhagem

Notebook documentando fonte, formato, proveniência, licença e a linhagem Kaggle → CSV → GitHub → Bronze → Silver → Gold → Análises.

2. Qualidade e consistência dos dados




Figura 3 — Verificação e tratamento de qualidade

Verificação de conversão de campos numéricos, com inspeção de valores e identificação de registros não convertíveis.




Figura 4 — Investigação de consistência música x artista

Verificação de inconsistências na associação entre músicas e artistas, utilizada nas validações de qualidade e modelagem.

3. Modelagem e persistência da camada Gold




Figura 5 — Persistência das tabelas da camada Gold

Gravação em Delta das dimensões, bridge e tabela fato da camada Gold, acompanhada da contagem de registros persistidos.

4. Evidências das análises




Figura 6 — Resultado P1: músicas com maior volume de streams

Tabela da P1 com Blinding Lights, Shape of You e Someone You Loved entre as músicas de maior volume de streams.




Figura 7 — Resultado P3: desempenho por período de lançamento

Tabela de desempenho por década, com quantidade de músicas, média, mediana e maior volume de streams por período.




Figura 8 — Execução da P4: comparação de características musicais

Código executado para comparar grupos por nível de streams e calcular médias de danceability, energy e valence.




Figura 9 — Execução da P5: concentração de streams associados aos artistas

Execução da análise de concentração de streams associados aos artistas usando fato, bridge música-artista e dimensão de artistas.

P2 — Relação entre presença em playlists e charts e volume de streams

A segunda análise busca verificar se músicas com maior presença em playlists e charts também apresentam maiores volumes de streams. Para isso, serão comparadas as métricas de streams com os indicadores de presença nas plataformas disponíveis na base, incluindo Spotify, Apple Music, Deezer e Shazam. A análise será realizada inicialmente por meio da relação entre essas variáveis, permitindo observar se maiores níveis de exposição nas plataformas tendem a acompanhar maiores volumes de reprodução. Como associação não implica causalidade, os resultados serão interpretados como relações observadas neste conjunto de dados, sem assumir que a presença em playlists ou charts seja, isoladamente, a causa do maior número de streams.

> correlacoes_p2: pyspark.sql.connect.dataframe.DataFrame = [variavel: string, registros_validos: long ... 1 more field]

	0 variavel	1 registros_validos	2 correlacao_streams
1	in_spotify_playlists	952	0.7898221599550612
2	in_apple_playlists	952	0.7720629840820624
3	in_deezer_playlists	952	0.5981310122534236
4	in_apple_charts	952	0.32023434128277684
5	in_spotify_charts	952	0.24582119983366885
6	in_deezer_charts	952	0.22859797355472555
7	in_shazam_charts	902	0.024981380996151808

7 rows 6.200s runtime Refreshed 42m

Figura 10 — Resultado P2: relação entre presença em playlists/charts e streams

Tabela de correlações da P2. A associação com streams é mais forte para playlists do Spotify (aprox. 0,79), Apple Music (aprox. 0,77) e Deezer (aprox. 0,60), enquanto as métricas de charts apresentam correlações menores.

Edit View Run Help Python Results Last edit was now Run all Serverless Schedule Comments

	0 artista	1 mbid	2 musica	3 rating	4 votos
1	The Weeknd	null	Blinding Lights	null	null
2	Ed Sheeran	c664a576-f0e5-4725-8d52-05ecfe4822d8	Shape of You	null	0
3	Harry Styles	5c942492-9757-4817-b8e8-7d41cf19adb6	As It Was	5	1

3 rows 5.297s runtime Refreshed 8m

Resultado da P6

O teste de integração com o MusicBrainz mostrou que a identificação das músicas entre as duas fontes é tecnicamente possível. No teste realizado, **Shape of You**, de Ed Sheeran e **As It Was**, de Harry Styles, foram localizadas com `score_matching` igual a **100** e receberam identificadores MBID. Para **Blinding Lights**, de The Weeknd, a execução mais recente não retornou correspondência válida, permanecendo `mbid`, `score_matching` e `titulo_encontrado` como nulos.

Entretanto, a consulta das avaliações mostrou cobertura insuficiente para sustentar a análise proposta. **Blinding Lights não apresentou avaliação disponível nem quantidade de votos informada, Shape of You não possuía avaliação e apresentava 0 votos, enquanto As It Was apresentou rating 5 com apenas 1 voto.**

Diante desse resultado, a coleta não foi ampliada para as demais músicas da base. Embora o relacionamento técnico entre as fontes tenha funcionado para parte do teste realizado, a quantidade de avaliações disponível não oferece evidência suficiente para representar de forma confiável a recepção dos usuários.

Por esse motivo, a sexta pergunta não foi respondida quantitativamente. A tentativa de enriquecimento foi mantida como parte do pipeline para registrar tanto a viabilidade técnica da integração quanto a limitação encontrada na fonte externa, evitando produzir uma associação entre popularidade e avaliação baseada em dados insuficientes.

Figura 11 — Resultado P6: disponibilidade de avaliações no MusicBrainz

Resultado final da P6. Blinding Lights não apresenta avaliação nem quantidade de votos informada; Shape of You não possui avaliação e apresenta 0 votos; As It Was apresenta rating 5 com 1 voto. A baixa cobertura não sustenta uma comparação quantitativa confiável entre desempenho e recepção dos usuários.

5. Cobertura das evidências

O conjunto consolidado documenta a fonte e a licença dos dados, a proveniência e linhagem, verificações de qualidade e consistência, a persistência da camada Gold e evidências das análises P1, P2, P3, P4, P5 e P6. As conclusões detalhadas e o código executável permanecem disponíveis no notebook final e no README do repositório.